调用OpenRouter大模型聚合服务

调用OpenRouter大模型聚合服务

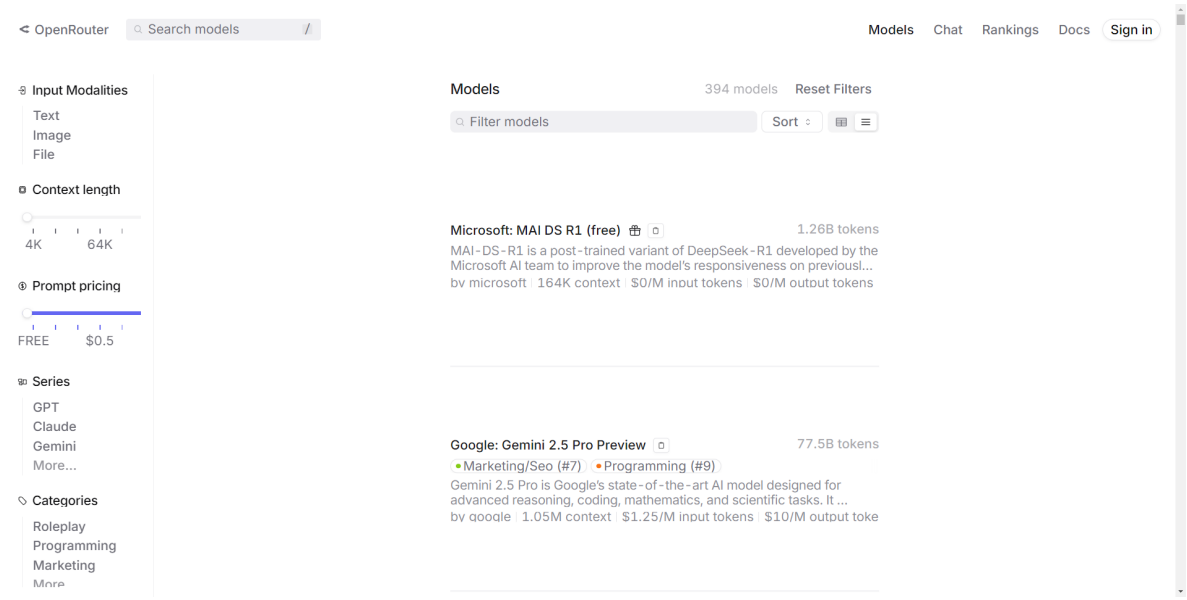
- 介绍
- 注册
- 使用
- 常见报错
  1. 请求错误: -1
  2. 401 No auth credentials found
  3. 卡在 “解析非流式响应 - 状态码: 200”
  4. 回复为空
  - 目前测试可用的模型列表如下:

介绍

> 本篇教程有较大操作难度

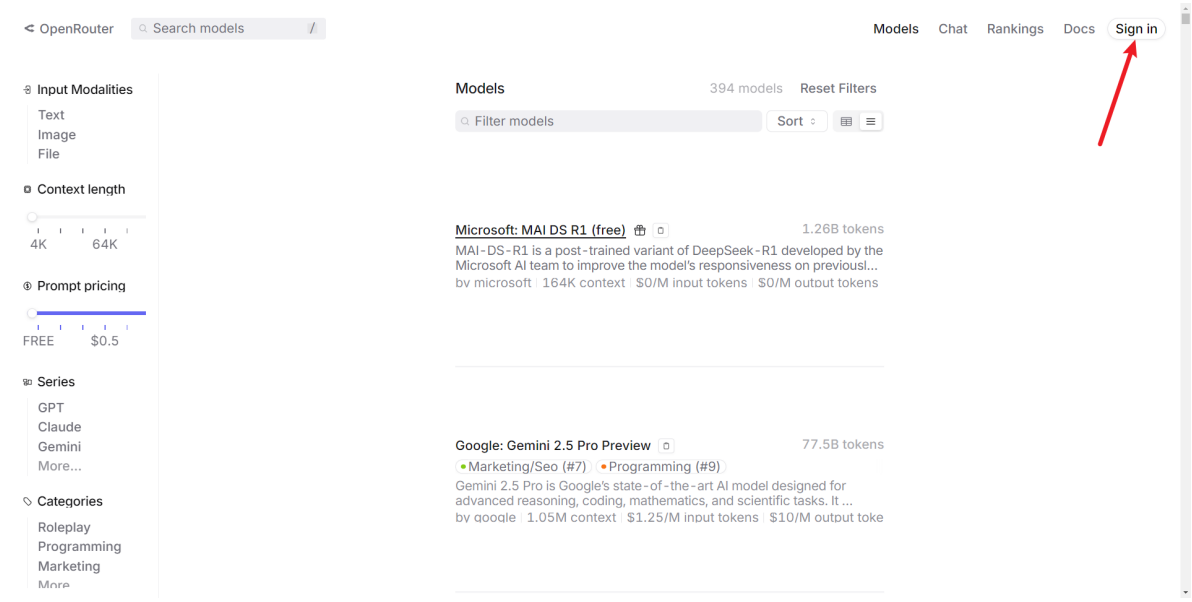
OpenRouter是一个聚合了大量的主流AI大语言模型API的平台，通过OpenRouter提供的服务，我们可以实现便捷的切换/调用各种各样的大模型

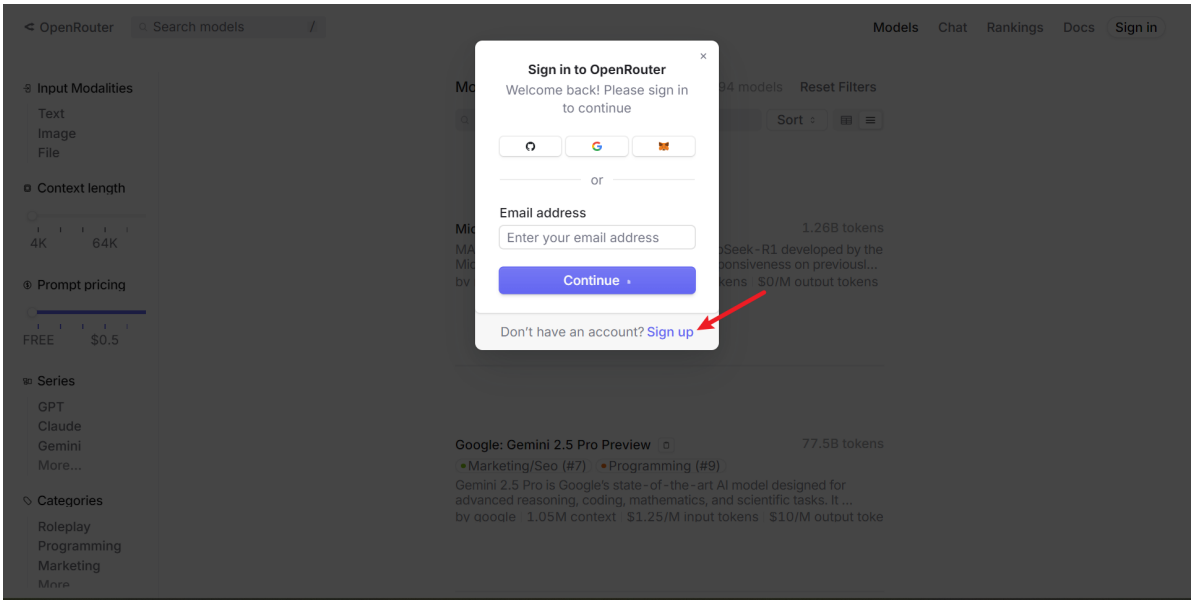
Models | OpenRouter

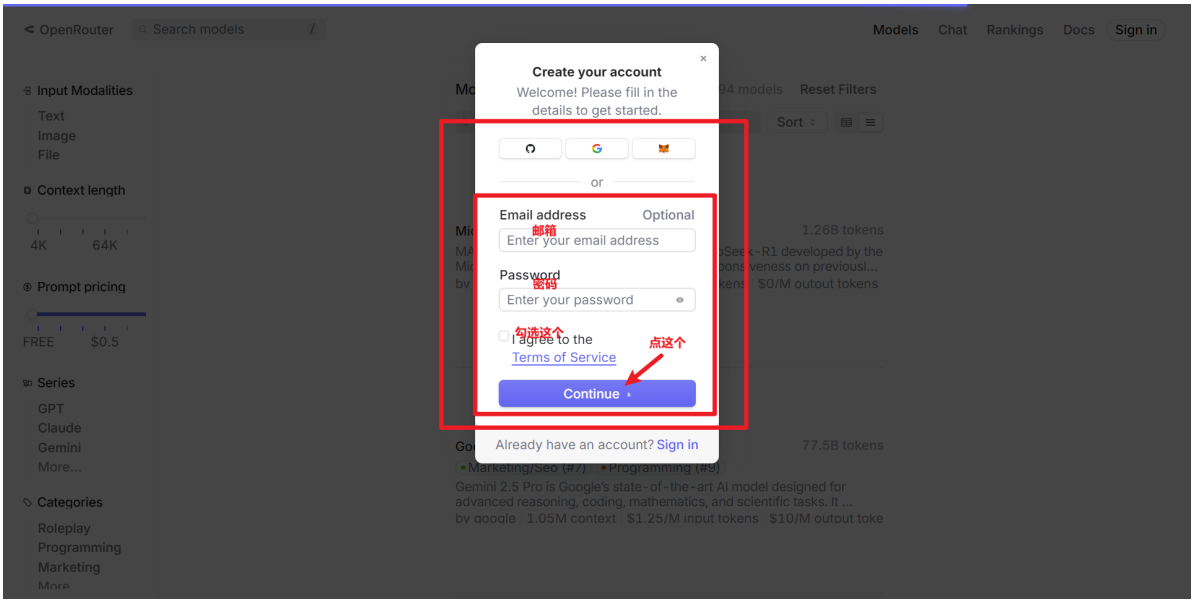


> 受各个大模型提供方的政策影响，OpenRouter上的部分模型无法访问，属于正常情况
>
> 关于不同大模型的收费情况，也由大模型提供方的政策决定
>
> 大部分情况下，免费的模型足够满足测试或简单的使用

注册

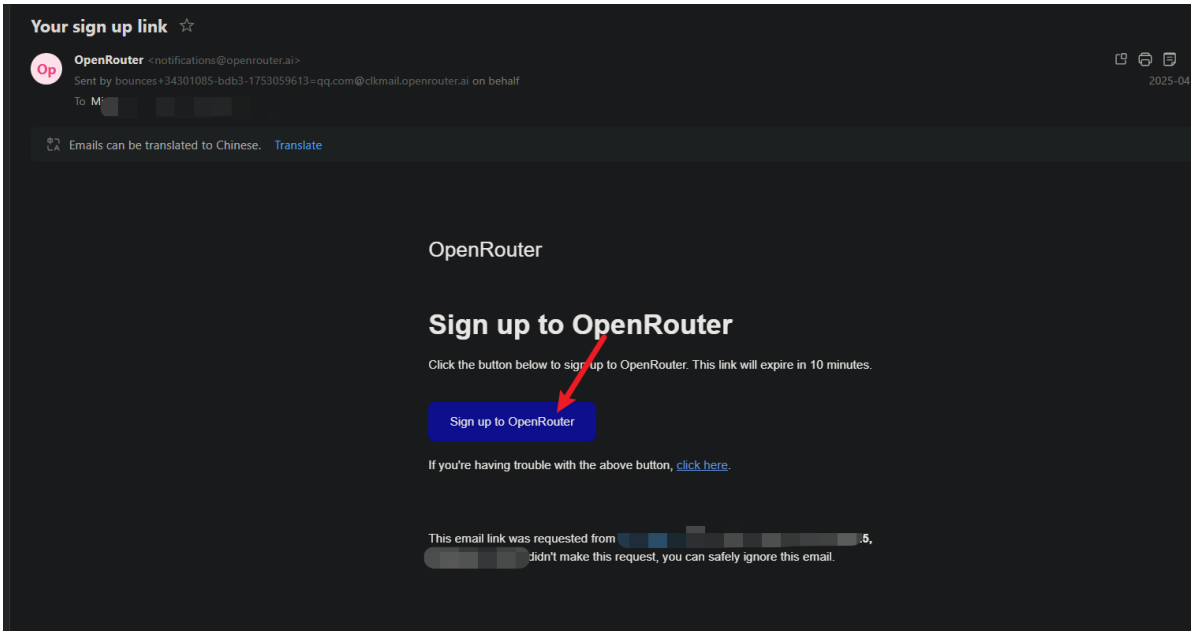




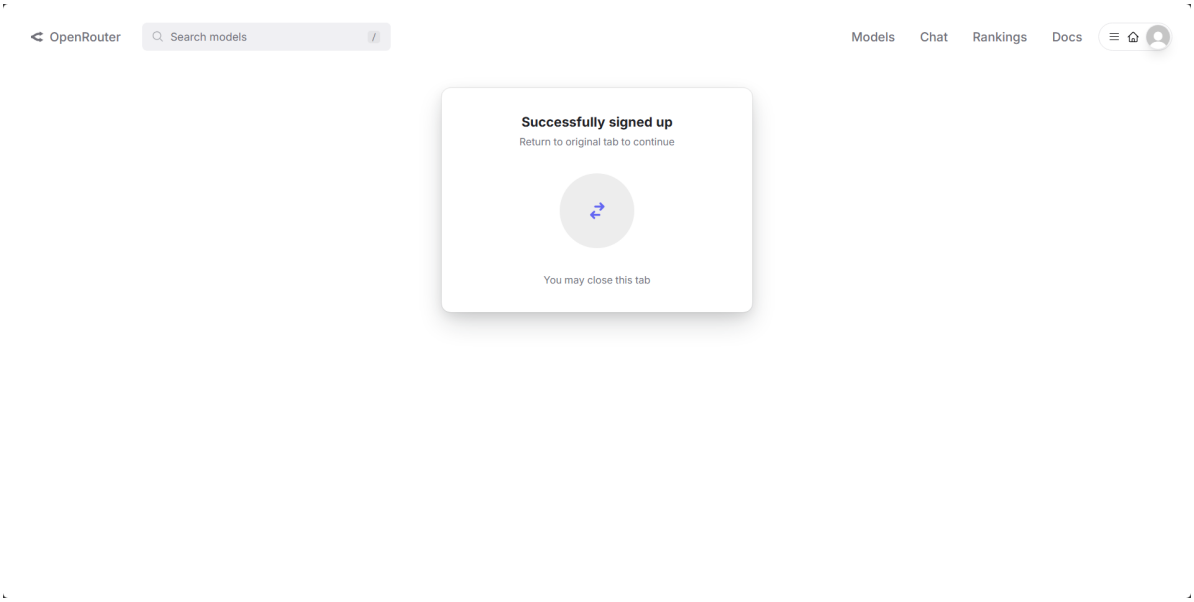


可以使用 github / Google / MetaMask钱包 或 其它邮箱进行注册

点击Continue后，OpenRouter会向你的邮箱发送一个验证链接

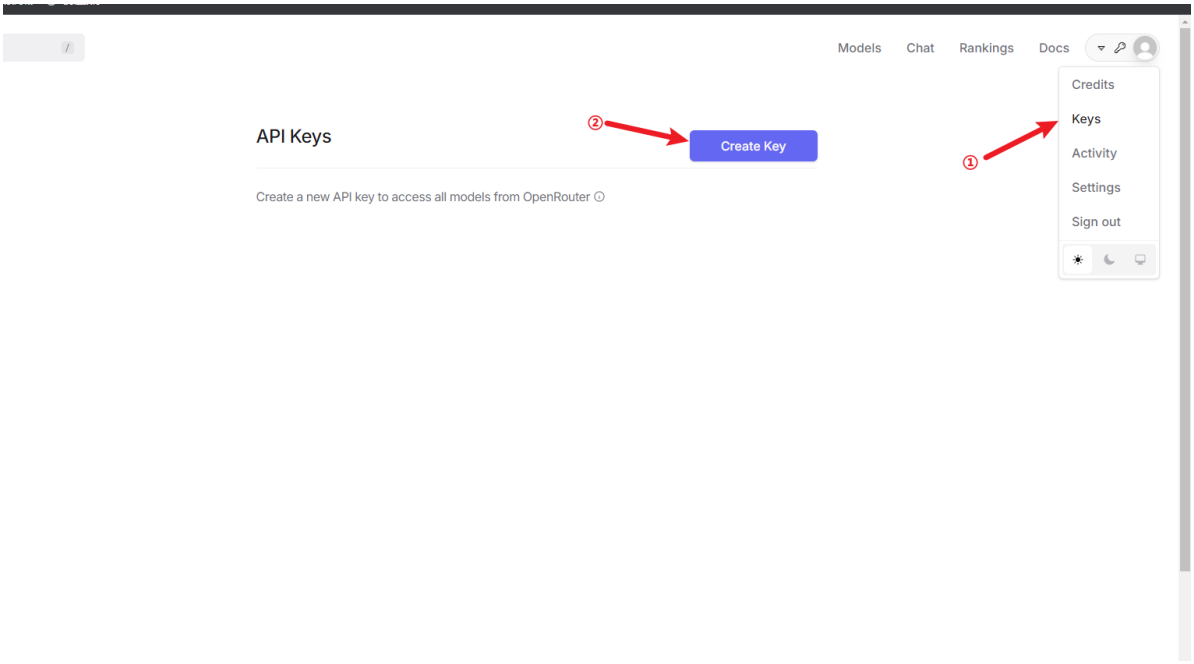


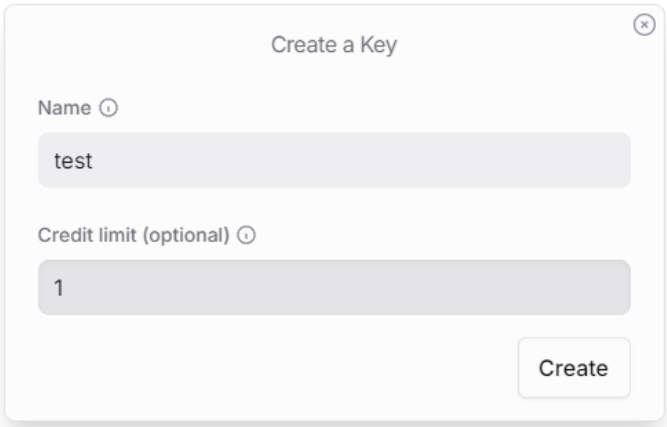
点击这个蓝色的按钮



弹出这个界面 说明注册成功了

接着我们来创建API秘钥



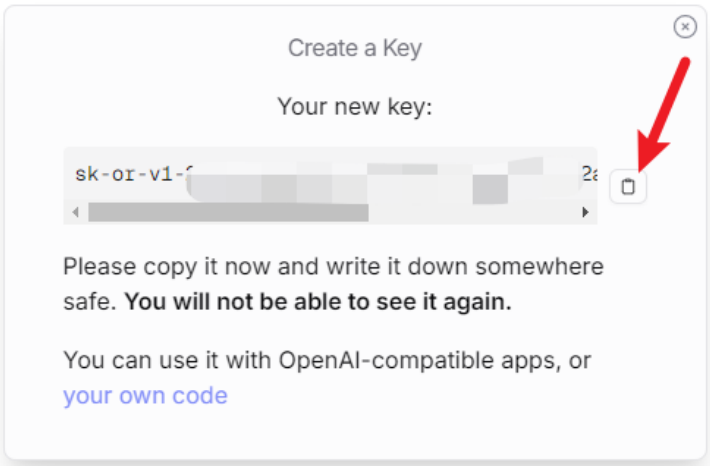


第一行是API名称，可以随意填写

第二行是API消费限制，可以留空

这个API Key生成后只会显示一次，请立刻复制该API Key，并记录下来

点击右边的按钮可以复制

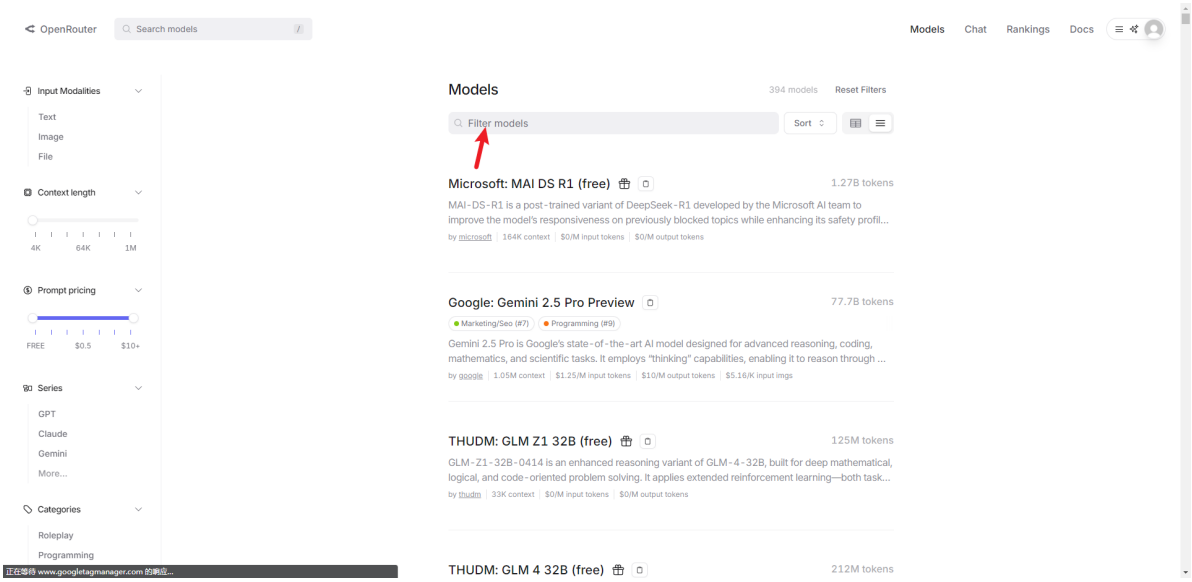


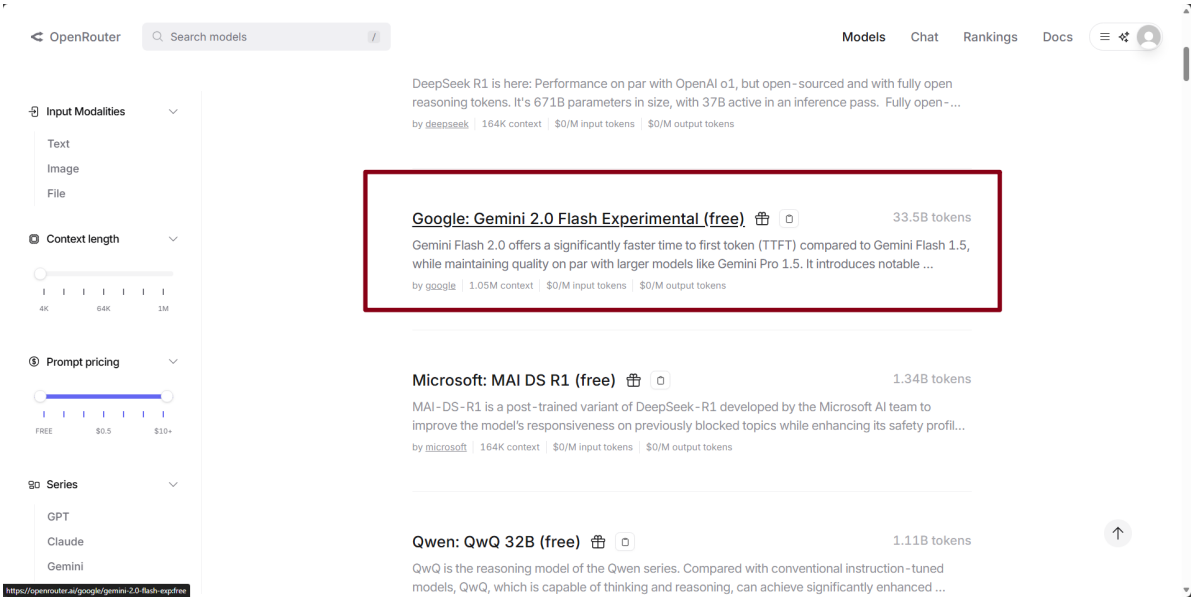
使用

我们先随便选一个模型测试一下

https://openrouter.ai/models

找到models页面，在这里输入 free





我们以Google的Gemini 2.0模型为例

> 注：实际搜索的时候，有些模型可能会失效。这里我们随便找一个标注了free的测试即可

点击这个模型，少数情况下可能会出现黑屏或卡死无反应的情况，但是不影响我们使用

我们只需要在连接后面加上一个/api，然后回车即可

比如我们现在浏览器中的链接是：

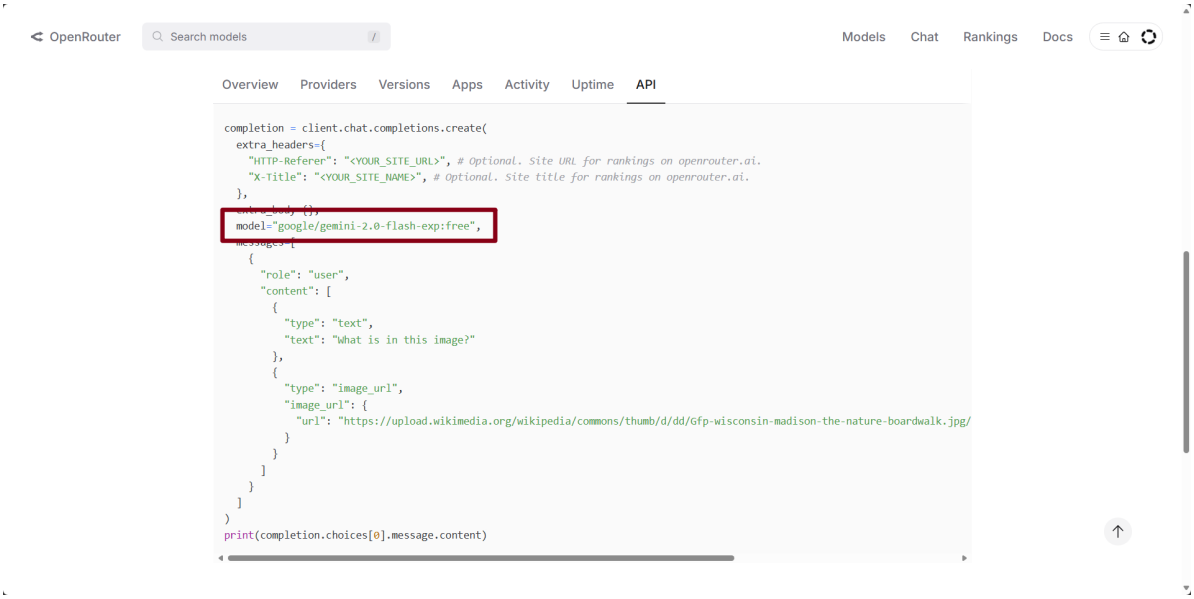
```
https://openrouter.ai/google/gemini-2.0-flash-exp:free
```

我们需要改为

```
https://openrouter.ai/google/gemini-2.0-flash-exp:free/api
```

然后回车访问即可

我们往下翻，找到这一段



复制这个模型名称

```
google/gemini-2.0-flash-exp:free
```

然后我们打开【源码汇总 / 11.Network / 08.LLM / llm_test.py】

```
from ybUtils.LLM import *

def network_use_wlan(ssid, key):
    import network
    sta = network.WLAN(0)
    sta.connect(ssid, key)
    while not sta.isconnected():
        time.sleep(1)
    return sta.ifconfig()[0]
# 测试代码
if __name__ == "__main__":

    # 连接网络
    print("等待连接网络 waiting connect to wifi")
    network_use_wlan("SSID", "PASSWORD")

    # Spark示例
    spark_api_key = "API Password"

    print("正在等待响应 ...")
    simple_chat_example(
        api_key=spark_api_key,
        prompt="给我唱首歌吧",
        model_type="openrouter",
        model="google/gemini-2.0-flash-exp:free"
    )
```

network_use_wlan方法里填写上WIFI名称和密码

spark_api_key参数设为刚刚我们保存的API Key

其它参数设置如下

```
model_type="openrouter",
model="google/gemini-2.0-flash-exp:free"
```

然后我们点击运行

如果第一次运行碰到如下报错

```
[DEBUG] 请求错误: -1
[DEBUG] 收到完整响应: {'error': {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type':
'request_error'}}
{'error': {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type': 'request_error'}}
错误: {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type': 'request_error'}
```

这是正常情况，我们只需要重新再运行一次即可

正常情况下，我们可以看到输出了如下信息：

```
[DEBUG] Request data length: 261
[DEBUG] Creating socket connection to openrouter.ai:443
[DEBUG] Resolved address: ('104.22.49.189', 443)
```

```
[DEBUG] Using HTTPS connection
[DEBUG] Received 1024 bytes
[DEBUG] Received 74 bytes
[DEBUG] Total response size: 1098 bytes
[DEBUG] Response status code: 200
[DEBUG] Closing connection
[DEBUG] 收到响应 - 状态码: 200
[DEBUG] 处理非流式响应
[DEBUG] 解析非流式响应 - 状态码: 200
[DEBUG] 成功解析响应: {'object': 'chat.completion', 'id': 'gen-1745492177-
eNQSFRRZvC1Dhavxo2Yp', 'model': 'google/gemini-2.0-flash-exp', 'usage':
{'total_tokens': 56, 'prompt_tokens': 10, 'completion_tokens': 46}, 'provider':
'Google AI Studio', 'created': 1745492177, 'choices': [{'index': 0,
'finish_reason': 'stop', 'logprobs': None, 'message': {'content':
'\u597d\u7684\uff0c\u7ed9\u4f60\u5531\u4e00\u9996\u7b80\u5355\u7684\u6b4c\uff1a\
n\n(\u8f7b\u8f7b\u54fc\u5531)\n\n\u4e00\u95ea\u4e00\u95ea\u4eae\u6676\u6676\uff0
c\n\u6ee1\u5929\u90fd\u662f\u5c0f\u661f\u661f\u3002\n\u6302\u5728\u5929\u4e0a\u6
53e\u5149\u660e\uff0c\n\u597d\u50cf\u8bb8\u591a\u5c0f\u773c\u775b\u3002\n\n\u600
e\u4e48\u6837\uff1f \U0001f60a\n', 'role': 'assistant', 'reasoning': None,
'refusal': None}, 'native_finish_reason': 'STOP'}]}
回复: 好的，给你唱一首简单的歌：

(轻轻哼唱)

一闪一闪亮晶晶，
满天都是小星星。
挂在天上放光明，
好像许多小眼睛。

怎么样？ 😊


使用的token: 56 (输入: 10, 输出: 46)
```

这样就说明交互成功了！！

常见报错

调用OpenRouter的大模型是一个较为复杂的过程，在调用过程中，我们很可能会遇到各种各样的问题

下面我们列举一些常见的异常情况

1. 请求错误: -1

```
[DEBUG] 请求错误: -1
[DEBUG] 收到完整响应: {'error': {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type':
'request_error'}}
{'error': {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type': 'request_error'}}
错误: {'message': '\u8bf7\u6c42\u9519\u8bef: -1', 'type': 'request_error'}
```

偶发性错误，在首次上电时出现的概率较高

请重新运行程序

2. 401 No auth credentials found

请检查一下API KEY填写正确了没有

```
[DEBUG] 处理非流式响应
[DEBUG] 解析非流式响应 - 状态码: 401
[DEBUG] 错误响应数据: {'error': {'message': 'No auth credentials found', 'code':
401}}
[DEBUG] 收到完整响应: {'error': {'message': 'No auth credentials found', 'code':
401}}
{'error': {'message': 'No auth credentials found', 'code': 401}}
错误: {'message': 'No auth credentials found', 'code': 401}
```

3. 卡在 “解析非流式响应 - 状态码: 200”

如果程序卡在这一步，请尝试换一个模型

```
[DEBUG] 收到响应 - 状态码: 200
[DEBUG] 处理非流式响应
[DEBUG] 解析非流式响应 - 状态码: 200
```

4. 回复为空

```
说明回复内容过长，内容被截断了。请重试
```

目前测试可用的模型列表如下：

> 大部分模型都是可以用的，我这里只测试了几个热度最高的模型

```
GOOGLE:google/gemini-2.0-flash-exp:free
DEEPSEEK:deepseek/deepseek-r1:free
微软：microsoft/mai-ds-r1:free
阿里通义千问:qwen/qwq-32b:free
```